

Objetivos da aula:

- Definir matrizes e reconhecer seus principais tipos (linha, coluna, quadrada, identidade, zero e transposta).
- Executar operações básicas: soma, multiplicação por escalar, matriz–vetor e matriz–matriz.
- Compreender o algoritmo “linha por coluna” da multiplicação matricial.
- Interpretar matrizes como transformações lineares no plano e no espaço.
- Reconhecer propriedades das transformações lineares, como preservação da origem, colinearidade e combinações lineares.
- Obter a matriz de uma transformação linear a partir da imagem dos vetores da base canônica.
- Visualizar transformações 2D com Python, interpretando deformações, rotações, cisalhamentos e reflexões.

Índice:

- I. Motivação computacional
- II. Matrizes: Definições e Operações Fundamentais
- III. Transformações Lineares
- IV. Visualização de Transformações Lineares

i. Motivação computacional

Até agora, o nosso universo era feito de vetores isolados (pontos, setas ou listas de dados). Mas, na computação moderna, raramente trabalhamos com um único dado de cada vez. Processamos milhares de imagens, milhões de transações financeiras ou bilhões de palavras simultaneamente.

Para organizar e processar esse volume massivo de informação, precisamos de uma estrutura mais robusta: a Matriz.

No entanto, em Ciência de Dados e IA, uma matriz tem uma "dupla personalidade" fascinante que precisamos entender desde o início:

1. A Matriz como Armazenamento (Database): É uma tabela estática de dados.
2. A Matriz como Máquina (Operador): É uma função ativa que transforma, estica, gira ou deforma vetores.

1. Datasets: O Mundo em Tabelas

A forma mais comum de encontrar uma matriz na indústria é através de um Dataset.

Imagine que estamos treinando um modelo para prever preços de casas. Temos dados de 100 casas, e para cada casa, temos 3 características (features): área, número de quartos e idade.

Matematicamente, organizamos isso em uma matriz X de dimensão 100×3 :

$$X = \begin{bmatrix} casa_1 \\ casa_2 \\ \vdots \\ casa_{100} \end{bmatrix} = \begin{bmatrix} 120 & 3 & 15 \\ 85 & 2 & 5 \\ \vdots & \vdots & \vdots \\ 200 & 4 & 30 \end{bmatrix}$$

- Linhas (row vectors): Representam as **amostras** (exemplos, instâncias, objetos).
- Colunas (column vectors): Representam as **features** (dimensões, atributos).

2. O "Motor" das Redes Neurais (Transformações Lineares)

Aqui entra a "segunda personalidade" da matriz, a mais importante para Deep Learning.

Pense em uma Rede Neural. O objetivo dela é pegar um vetor de entrada x (ex: os pixels de uma foto de um cachorro) e transformá-lo em um vetor de saída y (ex: as probabilidades $[0.9, 0.1]$ de ser "cachorro" ou "gato").

Como essa mágica acontece? Através de uma sequência de multiplicações de matrizes.

As "camadas" de uma rede neural são compostas por pesos (weights). Esses pesos são organizados em uma matriz W . O processamento da informação (o *forward pass*) é essencialmente calcular:

$$y = f(W \cdot x + b)$$

Neste contexto, a matriz W não é uma tabela de dados; ela é uma **função** ou uma **máquina**.

- O vetor x entra na máquina.
- A matriz W "mastiga" o vetor (gira, estica, combina as dimensões).
- O vetor y sai transformado do outro lado.

Quando dizemos que uma IA está "aprendendo", significa apenas que o algoritmo está ajustando os números dentro dessa matriz W até que a transformação que ela realiza seja capaz de converter corretamente "pixels de cachorro" na resposta "cachorro".

3. Conclusão

Nesta aula, vamos parar de ver matrizes apenas como tabelas estáticas e passaremos a vê-las como Transformações Lineares. Entender isso é a chave para responder perguntas como:

- "Por que preciso multiplicar matrizes?" (Para aplicar transformações em dados).
- "O que é o determinante?" (Quanto a matriz estica ou encolhe o espaço).
- "O que são autovetores?" (Eixos que resistem à rotação da matriz).

ii. Matrizes: Definições e Operações Fundamentais

Agora que entendemos o *porquê* (motivação), vamos entender o *como*. Para programar redes neurais ou manipular dados, precisamos dominar a sintaxe e a aritmética das matrizes.

O objetivo deste capítulo é apresentar, de forma sistemática e geométrica, o que são matrizes, como são representadas e quais operações fundamentais podemos realizar com elas.

1. Definição Formal de Matriz

Uma matriz é uma tabela retangular de números reais organizada em linhas e colunas. Denotamos uma matriz A de dimensão $m \times n$ como:

$$A = [a_{ij}]_{m \times n} \quad \text{com } i = 1, \dots, m \text{ e } j = 1, \dots, n$$

- m = número de linhas;
- n = número de colunas;
- a_{ij} = elemento da linha i e coluna j .

Exemplo:

$$A = \begin{bmatrix} 2 & -1 & 0 \\ 4 & 3 & 5 \end{bmatrix} \Rightarrow A \in \mathbb{R}^{2 \times 3}$$

Vetores como Matrizes Especiais

Vetor coluna $n \times 1$:

$$\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

Vetor linha $1 \times n$:

$$[x_1 \quad x_2 \quad \dots \quad x_n]$$

Assim, vetores são casos particulares de matrizes, ideia importante para unificar noções vistas nas Aulas 1 e 2.

2. Tipos Importantes de Matrizes

a. Matriz Linha e Matriz Coluna

- Linha: $A \in \mathbb{R}^{1 \times n}$
- Coluna: $A \in \mathbb{R}^{n \times 1}$

b. Matriz Quadrada

Quando $m = n$. Essas matrizes são essenciais para:

- determinantes;
- inversas;
- autovalores e autovetores;
- transformações lineares que mapeiam $\mathbb{R}^n \rightarrow \mathbb{R}^n$.

c. Matriz Identidade I_n

$$I_n = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

É o “1” multiplicativo das matrizes:

$$I_n x = x, \quad I_n A = A, \quad A I_n = A$$

d. Matriz Zero

Todos os elementos iguais a zero:

$$0_{m \times n}$$

3. Matriz Transposta

Além dos tipos de matrizes já apresentados (linha, coluna, quadrada, identidade e zero), existe uma operação fundamental que produz uma nova matriz a partir de outra: a transposição.

Definição:

Dada uma matriz A de dimensão $m \times n$:

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

a matriz transposta de A , denotada por A^T , é a matriz obtida trocando linhas por colunas:

$$A^T = \begin{bmatrix} a_{11} & a_{21} & \cdots & a_{m1} \\ a_{12} & a_{22} & \cdots & a_{m2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1n} & a_{2n} & \cdots & a_{mn} \end{bmatrix}$$

Em outras palavras:

$$(A^T)_{ij} = a_{ji}$$

Intuição

- A primeira linha de A vira a primeira coluna de A^T .
- A segunda linha vira a segunda coluna.
- E assim por diante.

A transposta reorganiza a matriz “girando-a” em torno de sua diagonal principal.

Exemplo: Se

$$A = \begin{bmatrix} 2 & -1 & 4 \\ 0 & 3 & 5 \end{bmatrix}$$

então sua transposta é

$$A^T = \begin{bmatrix} 2 & 0 \\ -1 & 3 \\ 4 & 5 \end{bmatrix}$$

Note que:

- A é 2×3 ;
- A^T é 3×2 .

Ou seja, a transposta sempre inverte as dimensões.

4. Operações Fundamentais com Matrizes

a. Igualdade de Matrizes

Duas matrizes são iguais quando:

- têm a **mesma dimensão**, e
- todos os elementos correspondentes são iguais.

$$A = B \Leftrightarrow a_{ij} = b_{ij} \forall i, j$$

b. Soma de Matrizes

Definida apenas para matrizes de mesma dimensão:

$$(A + B)_{ij} = a_{ij} + b_{ij}$$

Exemplo:

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} + \begin{bmatrix} 5 & 0 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 6 & 2 \\ 2 & 6 \end{bmatrix}$$

Interpretação: soma componente a componente, exatamente como com vetores.

c. Multiplicação por Escalar

Para $\lambda \in R$:

$$(\lambda A)_{ij} = \lambda a_{ij}$$

Exemplo:

$$2 \begin{bmatrix} 1 & -3 \\ 2 & 0 \end{bmatrix} = \begin{bmatrix} 2 & -6 \\ 4 & 0 \end{bmatrix}$$

d. Multiplicação Matriz–Vetor

Dada $A \in R^{m \times n}$ e $x \in R^n$:

$$Ax = x_1 v_1 + x_2 v_2 + \cdots + x_n v_n$$

onde $v_1, \dots, v_n$ são as colunas de A .

Ou seja:

$$Ax = \text{combinação linear das colunas}$$

Interpretação geométrica: A matriz A é uma transformação que “estica”, “inclina”, “projeta” ou “gira” o vetor x .

e. Multiplicação Matriz–Matriz

Multiplicar matrizes equivale a compor transformações lineares.

O elemento c_{ij} é:

$$c_{ij} = \sum_{k=1}^n a_{ik} b_{kj}$$

Para calcular o elemento c_{ij} da matriz resultado $C = AB$, pegamos a linha i da matriz A , sobrepomos à coluna j da matriz B , multiplicamos os elementos correspondentes e depois somamos os produtos. Esse processo é conhecido como o método “Linha por Coluna”.

$$\begin{bmatrix} a_{i1} & a_{i2} & \cdots & a_{in} \end{bmatrix} \text{ mergulha sobre } \begin{bmatrix} b_{1j} \\ b_{2j} \\ \vdots \\ b_{nj} \end{bmatrix}$$

Assim, a multiplicação matricial nada mais é do que combinar cada linha de A com cada coluna de B . A fórmula do somatório apenas formaliza esse processo “linha por coluna” que já ocorre naturalmente durante o cálculo.

5. Propriedades Importantes das Operações Matriciais

a. Soma

- Comutativa: $A + B = B + A$
- Associativa: $(A + B) + C = A + (B + C)$

b. Multiplicação por escalar

- $\lambda(\mu A) = (\lambda\mu)A$
- $1 A = A$

c. Multiplicação Matricial

- Associativa: $(AB)C = A(BC)$
- Distributiva:

$$A(B + C) = AB + AC$$

$$(A + B)C = AC + BC$$

Atenção: A multiplicação matricial **não é comutativa**:

$$AB \neq BA \quad \text{em geral}$$

iii. Transformações Lineares

No capítulo anterior, enxergamos a matriz não apenas como uma tabela de números, mas como uma máquina capaz de transformar vetores: esticar, girar, projetar, refletir, combinar dimensões e reorganizar informações. Agora vamos formalizar essa ideia: **toda transformação linear pode ser representada por uma matriz, e toda matriz representa uma transformação linear.**

1. O Conceito de Transformação Linear

Uma aplicação

$$T: R^n \rightarrow R^m$$

é chamada de **transformação linear** quando satisfaz duas propriedades essenciais:

(1) Preserva soma

$$T(u + v) = T(u) + T(v)$$

(2) Preserva multiplicação por escalar

$$T(\alpha u) = \alpha T(u)$$

Esses dois requisitos significam que a transformação respeita toda a estrutura do espaço vetorial. Em especial, isso implica:

- preserva a origem: $T(0) = 0$;
- preserva colinearidade (dois vetores ou dois pontos são colineares quando pertencem à mesma reta, isto é, quando um pode ser escrito como múltiplo escalar do outro);
- transforma combinações lineares em combinações lineares;
- não cria “curvaturas” ou “dobras” no espaço.

Em termos geométricos:

Transformações lineares preservam retas, planos e paralelismo. Elas podem distorcer o espaço, mas sempre de forma “reta”.

2. Toda Transformação Linear é Representada por Matrizes

Uma das descobertas mais profundas da Álgebra Linear é que **toda transformação linear em R^n** pode ser escrita como uma multiplicação matricial:

$$T(x) = A x$$

A matriz A :

- codifica a ação da transformação;
- contém nas colunas as imagens dos vetores da base canônica;
- permite aplicar a transformação a milhares de vetores ao mesmo tempo (como ocorre em ML).

Como obter a matriz de uma transformação linear?

Basta ver onde T envia os vetores da base canônica:

$$e_1 = (1, 0, \dots, 0), \quad e_2 = (0, 1, \dots, 0), \quad \dots$$

As colunas da matriz são:

$$A = [T(e_1) \quad T(e_2) \quad \dots \quad T(e_n)]$$

Isto conecta diretamente com a noção de colunas como “direções fundamentais”.

3. Interpretação Geométrica das Transformações Lineares

Transformações lineares são ferramentas poderosas para descrever como o espaço é alterado. A seguir, vemos as mais típicas em R^2 , pois são fáceis de visualizar e ocorrem constantemente em Computação Gráfica, Visão Computacional e ML:

a) Escalonamentos (Dilatações/Compressões)

Exemplo:

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$$

O efeito é:

- dobrar a largura;
- manter a altura.

No plano, isso “esticaria” o eixo x .

b) Cisalhamentos

$$A = \begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}$$

Aqui, cada vetor é “empurrado” horizontalmente dependendo de sua coordenada vertical. É muito usado em animações e gráficos.

c) Reflexões

Exemplo: reflexão no eixo x :

$$A = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$

Inverte o sentido vertical; mantém o horizontal.

d) Rotações

$$R_\theta = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$$

Rotações preservam normas e ângulos (matricialmente, têm determinante 1 e colunas ortonormais).

É a transformação linear mais usada em visão computacional e robótica.

4. Composição de Transformações Lineares

Se:

$$T_1(x) = Ax, \quad T_2(x) = Bx$$

então aplicar primeiro T_1 e depois T_2 dá:

$$T_2(T_1(x)) = B(Ax) = (BA)x$$

Isto mostra que:

- compor transformações = multiplicar matrizes;
- a ordem importa: $BA \neq AB$, na maioria dos casos.

Em Deep Learning, isto modela exatamente a arquitetura de uma rede neural.

$$x \xrightarrow{A_1} h_1 \xrightarrow{A_2} h_2 \xrightarrow{A_3} \dots \xrightarrow{A_n} y$$

Cada camada é uma transformação linear, e toda a rede é sua composição matricial.

5. Transformações Lineares e Matrizes de Mudança de Base

Este ponto conecta diretamente com o final da Aula 2 (Coordenadas e Mudança de Base).

Se mudamos a base do espaço, a matriz que representa a mesma transformação muda. Para uma base B e matriz de mudança P :

$$[T]_B = P^{-1}AP$$

Este conceito é fundamental para diagonalização e PCA (Análise de Componentes Principais).

iv. Visualização de Transformações Lineares

A melhor forma de entender transformações lineares é vê-las atuando no espaço. A seguir, visualizaremos rotações, cisalhamentos, reflexões, escalonamentos e combinações matriciais usando Python, NumPy e Matplotlib.

1. Código Base: Gerar e Plotar Grades 2D

Monte um notebook no Colab e coloque cada código em uma célula. Coloque o código a seguir na 1ª célula.

Ao executar o código não teremos saída, pois as funções aqui definidas serão usadas pelos demais exemplos para plotar a grade original e a transformada pela matriz A .

A função `gerar_grade` cria uma grade combinando as seguintes coordenadas, totalizando 16 pontos.

```
xs: [-2.  -0.67  0.67  2.]
ys: [-2.  -0.67  0.67  2.]
```

```
import numpy as np
import matplotlib.pyplot as plt
# altere o valor de n para obter mais o menos pontos
def gerar_grade(n=4, limite=2):
    """Gera um conjunto de vetores formando uma grade no plano."""
    xs = np.linspace(-limite, limite, n)
    ys = np.linspace(-limite, limite, n)
    pontos = []

    for x in xs:
        for y in ys:
            pontos.append([x, y])

    return np.array(pontos)

def aplicar_transformacao(A, pontos):
    """Aplica a transformação linear Ax a cada ponto."""
    return pontos @ A.T # (N,2) @ (2,2)

def plotar_transformacao(A, titulo="Transformação Linear"):
    pontos = gerar_grade()
    pontos_T = aplicar_transformacao(A, pontos)

    plt.figure(figsize=(6,6))

    # grade original
    plt.scatter(pontos[:,0], pontos[:,1], s=10, alpha=0.3, color='blue',
label='Original')

    # grade transformada
    plt.scatter(pontos_T[:,0], pontos_T[:,1], s=10, alpha=0.6, color='red',
label='Transformado')

    plt.axhline(0, color='black', linewidth=0.5)
    plt.axvline(0, color='black', linewidth=0.5)

    plt.title(titulo)
    plt.legend()
    plt.grid(True, linestyle='--', alpha=0.3)
    plt.gca().set_aspect('equal')
    plt.show()
```

Nota: Na álgebra linear clássica, costumamos escrever vetores como colunas (Ax). Porém, em Computação e Data Science, costumamos organizar dados em linhas (cada linha é uma amostra). Por isso, no código, multiplicamos a matriz de dados pela matriz de transformação transposta à direita.

```
def aplicar_transformacao(A, pontos):
    """Aplica a transformação linear Ax a cada ponto."""
    return pontos @ A.T # (N,2) @ (2,2)
```

2. Escalonamento (Stretching / Compressão)

Multiplicamos as coordenadas por fatores diferentes:

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 0.5 \end{bmatrix}$$


O efeito é:

- dobra o eixo x ;
- comprime o eixo y pela metade.

Coloque o código na 2ª célula do notebook.

```
A = np.array([[2, 0],
              [0, 0.5]])
```

```
plotar_transformacao(A, "Escalonamento: alonga x, comprime y")
```



3. Cisalhamento (Shear)

$$A = \begin{bmatrix} 1 & k \\ 0 & 1 \end{bmatrix}$$

O eixo x é inclinado proporcionalmente a y .



Coloque o código na 3ª célula do notebook.

```
k = 1.0
```

```
A = np.array([[1, k],
              [0, 1]])
```

```
plotar_transformacao(A, f"Cisalhamento horizontal (k={k})")
```

Altere o valor da variável `k` para ver o resultado



4. Rotação no Plano

$$R_{\theta} = \begin{bmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{bmatrix}$$



Coloque o código na 4ª célula do notebook.

```
theta = np.pi / 4 # 45 graus
theta_graus = np.degrees(theta)
```

```
A = np.array([[np.cos(theta), -np.sin(theta)],
               [np.sin(theta), np.cos(theta)]])
```

```
plotar_transformacao(A, f"Rotação de {theta_graus:.0f}°")
```

Altere o valor para `np.pi / 3` ver o resultado.



5. Reflexão em uma Linha


Reflexão no eixo x:

$$A = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$

Coloque o código na 5ª célula do notebook.

```
A = np.array([[1, 0],
              [0, -1]])
```

```
plotar_transformacao(A, "Reflexão no eixo X")
```



6. Projeção em uma Reta

Projeção no eixo x:



$$A = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

Coloque o código na 6ª célula do notebook.

```
A = np.array([[1, 0],
              [0, 0]])
```

```
plotar_transformacao(A, "Projeção no eixo X")
```

Altere a matriz para $\begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$ para projetar no eixo y.



7. Combinação de Transformações (Composição)

Agora aplicamos uma operação composta, mostrando que:

$$BA \neq AB$$


Vamos compor uma rotação seguida de cisalhamento.

```
theta = np.pi/4 # rotação de 45°
R = np.array([[np.cos(theta), -np.sin(theta)],
              [np.sin(theta),  np.cos(theta)]])

# cisalhamento k=1
S = np.array([[1, 1],
              [0, 1]])

A = S @ R # primeiro rotaciona, depois cisalha

plotar_transformacao(A, "Rotação + Cisalhamento (S @ R)")
```



Exercícios

Exercício 1 – Dimensão e tipos de matrizes

Considere as matrizes:

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}, \quad B = \begin{bmatrix} 2 & 0 \\ -1 & 3 \end{bmatrix}, \quad C = \begin{bmatrix} 1 & 0 & 0 \end{bmatrix}$$

- Determine a dimensão (número de linhas e colunas) de cada matriz.
- Classifique cada uma como: matriz linha, coluna, quadrada ou nenhuma destas.
- Escreva a transposta de C .

Resposta:

- $A \in R^{2 \times 3}$, $B \in R^{2 \times 2}$ e $C \in R^{1 \times 3}$
- A : não é quadrada, nem linha nem coluna (2x3);
 B : matriz quadrada (2x2);

C : matriz linha (1x3).

c) $C^T = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}$

Exercício 2 – Operações básicas com matrizes

Sejam

$$A = \begin{bmatrix} 1 & -2 \\ 0 & 3 \end{bmatrix}, \quad B = \begin{bmatrix} 4 & 1 \\ -1 & 2 \end{bmatrix}$$

- a) Calcule $A + B$.
- b) Calcule $2A - B$.
- c) Calcule a transposta de A , isto é, A^T .

Resposta:

- a) $A + B = \begin{bmatrix} 1+4 & -2+1 \\ 0-1 & 3+2 \end{bmatrix} = \begin{bmatrix} 5 & -1 \\ -1 & 5 \end{bmatrix}$
- b) $2A = \begin{bmatrix} 2 & -4 \\ 0 & 6 \end{bmatrix}$, $2A - B = \begin{bmatrix} 2-4 & -4-1 \\ 0+1 & 6-2 \end{bmatrix} = \begin{bmatrix} -2 & -5 \\ 1 & 4 \end{bmatrix}$
- c) $A^T = \begin{bmatrix} 1 & 0 \\ -2 & 3 \end{bmatrix}$

Exercício 3 – Multiplicação matriz-vetor e combinação linear

Considere

$$A = \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix}, \quad x = \begin{bmatrix} 4 \\ 1 \end{bmatrix}$$

- a) Calcule Ax .
- b) Escreva o vetor Ax como combinação linear das colunas de A .

Resposta:

- a) $Ax = \begin{bmatrix} 2 & 1 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} 4 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \cdot 4 + 1 \cdot 1 \\ -1 \cdot 4 + 3 \cdot 1 \end{bmatrix} = \begin{bmatrix} 8+1 \\ -4+3 \end{bmatrix} = \begin{bmatrix} 9 \\ -1 \end{bmatrix}$
- b) As colunas de A são

$$v_1 = \begin{bmatrix} 2 \\ -1 \end{bmatrix}, \quad v_2 = \begin{bmatrix} 1 \\ 3 \end{bmatrix}$$

Temos

$$Ax = 4v_1 + 1v_2 = 4 \begin{bmatrix} 2 \\ -1 \end{bmatrix} + 1 \begin{bmatrix} 1 \\ 3 \end{bmatrix} = \begin{bmatrix} 8 \\ -4 \end{bmatrix} + \begin{bmatrix} 1 \\ 3 \end{bmatrix} = \begin{bmatrix} 9 \\ -1 \end{bmatrix}$$

Logo, Ax é a combinação linear $4v_1 + v_2$.

Exercício 4 – Multiplicação matriz-matriz (algoritmo linha por coluna)

Sejam

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \quad B = \begin{bmatrix} 0 & 1 \\ -1 & 2 \end{bmatrix}$$

- a) Calcule $C = AB$ usando explicitamente o método “linha por coluna”.
- b) Verifique o elemento c_{21} usando a fórmula do somatório.

Resposta:

a)

- c_{11} : linha 1 de A com coluna 1 de B :

$$c_{11} = 1 \cdot 0 + 2 \cdot (-1) = -2$$

- c_{12} : linha 1 de A com coluna 2 de B :

$$c_{12} = 1 \cdot 1 + 2 \cdot 2 = 1 + 4 = 5$$

- c_{21} : linha 2 de A com coluna 1 de B :

$$c_{21} = 3 \cdot 0 + 4 \cdot (-1) = -4$$

- c_{22} : linha 2 de A com coluna 2 de B :

$$c_{22} = 3 \cdot 1 + 4 \cdot 2 = 3 + 8 = 11$$

Logo,

$$C = AB = \begin{bmatrix} -2 & 5 \\ -4 & 11 \end{bmatrix}$$

b) Pela fórmula

$$c_{21} = \sum_{k=1}^2 a_{2k} b_{k1} = a_{21}b_{11} + a_{22}b_{21} = 3 \cdot 0 + 4 \cdot (-1) = -4$$

coincidindo com o resultado obtido pelo método “linha por coluna”.

Exercício 5 – Verificando se uma transformação é linear

Considere a aplicação $T: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ definida por:

$$T(x, y) = (2x - y, 3x + y)$$

a) Mostre que T é uma transformação linear verificando as duas propriedades:

i. $T(u + v) = T(u) + T(v)$;

ii. $T(\alpha u) = \alpha T(u)$.

b) Encontre a matriz A tal que $T(x) = Ax$, onde $x = \begin{bmatrix} x \\ y \end{bmatrix}$.

Resposta:

a) Sejam $u = (x_1, y_1)$ e $v = (x_2, y_2)$.

- Soma:

$$u + v = (x_1 + x_2, y_1 + y_2)$$

$$T(u + v) = (2(x_1 + x_2) - (y_1 + y_2), 3(x_1 + x_2) + (y_1 + y_2))$$

Desenvolvendo:

$$T(u + v) = (2x_1 + 2x_2 - y_1 - y_2, 3x_1 + 3x_2 + y_1 + y_2)$$

Por outro lado:

$$T(u) = (2x_1 - y_1, 3x_1 + y_1), \quad T(v) = (2x_2 - y_2, 3x_2 + y_2)$$

$$T(u) + T(v) = (2x_1 - y_1 + 2x_2 - y_2, 3x_1 + y_1 + 3x_2 + y_2)$$

que é exatamente o mesmo que $T(u + v)$.

- Multiplicação por escalar:

Seja $\alpha \in R$ e $u = (x, y)$.

$$\alpha u = (\alpha x, \alpha y)$$

$$T(\alpha u) = (2\alpha x - \alpha y, 3\alpha x + \alpha y) = \alpha(2x - y, 3x + y) = \alpha T(u)$$

Logo, T é linear.

- b) Basta observar a imagem dos vetores da base canônica:

$$T(1,0) = (2,3), \quad T(0,1) = (-1,1)$$

Assim, a matriz de T (com colunas $T(e_1)$ e $T(e_2)$) é:

$$A = \begin{bmatrix} 2 & -1 \\ 3 & 1 \end{bmatrix}$$

de modo que

$$T(x, y) = A \begin{bmatrix} x \\ y \end{bmatrix}$$

Exercício 6 – Camada linear de rede neural (sem viés)

Uma camada totalmente conectada (sem viés) em uma rede neural é dada por:

$$y = Wx$$

onde W é a matriz de pesos, x é o vetor de entrada e y é o vetor de saída.

Considere

$$W = \begin{bmatrix} 1 & -1 & 2 \\ 0 & 3 & 1 \end{bmatrix}, \quad x = \begin{bmatrix} 2 \\ 1 \\ -1 \end{bmatrix}$$

- Calcule a saída y .
- Interprete o resultado como combinação linear das colunas de W .

Resposta:

$$a) \quad y = Wx = \begin{bmatrix} 1 & -1 & 2 \\ 0 & 3 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \cdot 2 + (-1) \cdot 1 + 2 \cdot (-1) \\ 0 \cdot 2 + 3 \cdot 1 + 1 \cdot (-1) \end{bmatrix} = \begin{bmatrix} 2 - 1 - 2 \\ 0 + 3 - 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 2 \end{bmatrix}$$

- b) As colunas de W são:

$$w_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad w_2 = \begin{bmatrix} -1 \\ 3 \end{bmatrix}, \quad w_3 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

Temos:

$$y = 2w_1 + 1w_2 + (-1)w_3 = 2 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \begin{bmatrix} -1 \\ 3 \end{bmatrix} - \begin{bmatrix} 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 - 1 - 2 \\ 0 + 3 - 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 2 \end{bmatrix}$$

Logo, a saída é uma combinação linear das colunas de W , com coeficientes dados pelas entradas de x . Em termos de rede neural, cada coluna de W representa como uma feature de entrada contribui para os neurônios de saída.

Exercício 7 – Núcleo e imagem de uma transformação

Considere a matriz

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

- a) Encontre um vetor não nulo $v \in \mathbb{R}^2$ tal que $Av = 0$ (isto é, um vetor no núcleo de A).
- b) Descreva geometricamente a imagem de A (subespaço gerado pelas colunas).

Resposta:

- a) Queremos $v = (x, y)$ tal que

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Isso gera o sistema:

$$\begin{cases} x + 2y = 0 \\ 2x + 4y = 0 \end{cases}$$

As equações são múltiplas; basta resolver a primeira:

$$x = -2y$$

Escolhendo por exemplo $y = 1$, obtemos $x = -2$. Logo,

$$v = \begin{bmatrix} -2 \\ 1 \end{bmatrix}$$

é um vetor não nulo no núcleo de A .

- b) As colunas de A são:

$$c_1 = \begin{bmatrix} 1 \\ 3 \end{bmatrix}, \quad c_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix} = 2c_1$$

Assim, ambas estão na mesma reta. Logo, a imagem de A é o subespaço gerado por c_1 , isto é, uma reta passando pela origem em $\mathbb{R}^2$.